

So sánh CNN, ResNet và Vision Transformers cho Phân loại Đa nhãn Bệnh tật nh X-quang Ngực

Đ án cuối kỳ môn Deep Learning - Nhóm 1
Trng Kinh doanh - Thc sĩ Kinh t

Thành viên Nhóm 1

February 5, 2026

Abstract

Báo cáo này trình bày nghiên cứu so sánh ba kiến trúc deep learning chính cho bài toán phân loại đa nhãn bệnh phi t nh X-quang ngực: Convolutional Neural Networks (CNN), Residual Networks (ResNet-34), và Vision Transformers (ViT). Chúng tôi thực hiện các mô hình t đư bng PyTorch và so sánh vi mô hình ViT tin hun lun t th vin timm. Kt qu cho thý: (1) ViT pretrained đt AUC cao nht (0.67), (2) các mô hình hun lun t đư vi d liu nh cho hieu sut thp hn, (3) transfer learning là cn thit cho ng dng y khoa, (4) AUC là metric quan trng hn accuracy do class imbalance nghiêm trng. B d liu s dng là NIH Chest X-ray 14 vi 112,120 nh và 15 lp bnh.

T khóa: Vision Transformer, X-quang ngực, Phân loại đa nhãn, Deep Learning, Hình nh y khoa, Transfer Learning

Contents

Part I

Các Mô Hình Deep Learning

1 Mô hình CNN cơ sở

1.1 Kiến trúc mô hình

Mô hình CNN cơ sở (**CNNClassifier**) được thiết kế như một baseline để so sánh với các kiến trúc phức tạp hơn. Kiến trúc này bao gồm hai khối tích chập (convolutional block) và một lớp phân loại fully-connected.

Chi tiết kiến trúc:

- **Đầu vào:** ảnh RGB kích thước $3 \times 224 \times 224$
- **Khối tích chập 1:**
 - Conv2d: 3 channels \rightarrow 32 channels, kernel 3×3 , không padding
 - Activation: ReLU
 - MaxPool2d: kernel 2×2
 - Kích thước sau khi: $32 \times 111 \times 111$
- **Khối tích chập 2:**
 - Conv2d: 32 channels \rightarrow 64 channels, kernel 3×3 , không padding
 - Activation: ReLU
 - MaxPool2d: kernel 2×2
 - Kích thước sau khi: $64 \times 54 \times 54$
- **Lớp phân loại (Classifier):**
 - Flatten: $64 \times 54 \times 54 = 186,624$ features
 - Linear: $186,624 \rightarrow 512$
 - ReLU
 - Linear: $512 \rightarrow 15$ (số lớp bệnh)

Tổng số tham số: ~ 95 triệu tham số

Vấn đề kiến trúc: Việc sử dụng Flatten trực tiếp sau các lớp tích chập dẫn đến lớp fully-connected đầu tiên có số tham số rất lớn ($186,624 \times 512 \approx 95.5\text{M}$). Đây là một thiết kế không hiệu quả, nên được thay thế bằng Global Average Pooling để giảm đáng kể số tham số.

1.2 Cấu hình huấn luyện

Table 1: Cấu hình huấn luyện mô hình CNN

Tham số	Giá trị
Kích thước ảnh (Image Size)	224×224
Batch Size	32
Learning Rate	1×10^{-4}
Weight Decay	1×10^{-6}
Số Epoch	10
Optimizer	AdamW
Loss Function	BCEWithLogitsLoss

Data Augmentation áp dụng trong quá trình huấn luyện:

- Horizontal Flip vì xác suất $p = 0.5$
- Random Rotation trong phạm vi ± 5
- Color Jitter: brightness=0.1, contrast=0.1
- Normalization sđng mean và std của ImageNet: $\mu = [0.485, 0.456, 0.406]$, $\sigma = [0.229, 0.224, 0.225]$

1.3 Kết quả thực nghiệm

Table 2: Kết quả huấn luyện mô hình CNN (10 epoch)

Chỉ số	Train	Validation	Test
Loss (epoch cuối)	0.2121	0.4208	–
AUC (epoch cuối)	0.8961	0.5847	~0.58
Best Val AUC	–	0.5998 (epoch 1)	–

Nhận xét:

- **Overfitting nghiêm trọng:** Train AUC tăng từ 0.53 lên 0.90 trong khi Val AUC gần như không có biến động (dao động quanh 0.56–0.60).
- **Best epoch là epoch 1:** Mô hình đạt Best Val AUC = 0.5998 ngay từ epoch đầu tiên, sau đó validation performance giảm dần.
- **Không cách Train-Val gap:** Rất lớn (~0.32), cho thấy mô hình học thực địa huấn luyện thay vì tổng quát hóa.

1.4 Đơn mã minh họa

```

1 class CNNClassifier(nn.Module):
2     def __init__(self, num_classes=15):
3         super(CNNClassifier, self).__init__()
4         # Input: 3 x 224 x 224
5         self.features = nn.Sequential(
6             # Conv Block 1
7             nn.Conv2d(3, 32, kernel_size=3, padding=0),
8             nn.ReLU(),
9             nn.MaxPool2d(kernel_size=2),
10            # Conv Block 2
11            nn.Conv2d(32, 64, kernel_size=3, padding=0),
12            nn.ReLU(),
13            nn.MaxPool2d(kernel_size=2)
14        )
15        # 224 -> 222 -> 111 -> 109 -> 54
16        self.flatten_size = 64 * 54 * 54 # = 186,624
17
18        self.classifier = nn.Sequential(
19            nn.Flatten(),
20            nn.Linear(self.flatten_size, 512),
21            nn.ReLU(),
22            nn.Linear(512, num_classes)
23        )
24
25    def forward(self, x):
26        x = self.features(x)
27        x = self.classifier(x)
28        return x

```

Listing 1: Định nghĩa lớp CNNClassifier

2 Mô hình ResNet-34

2.1 Kiến trúc mô hình

Mô hình ResNet-34 được xây dựng từ đầu (from scratch) theo kiến trúc gốc của He et al. (2016). Đặc điểm quan trọng nhất của ResNet là **skip connections** (residual connections), cho phép gradient lan truyền trực tiếp qua nhiều lớp, giải quyết vấn đề vanishing gradient trong các mạng sâu.

Cấu trúc BasicBlock:

- Conv2d (3×3) \rightarrow BatchNorm2d \rightarrow ReLU
- Conv2d (3×3) \rightarrow BatchNorm2d
- Skip connection: $output = F(x) + x$
- ReLU activation cuối cùng

Cấu hình ResNet-34:

Table 3: Cấu hình các layer trong ResNet-34

Layer	Channels	Blocks	Stride	Output Size
Conv1 (7×7)	64	–	2	112×112
MaxPool	64	–	2	56×56
Layer1	64	3	1	56×56
Layer2	128	4	2	28×28
Layer3	256	6	2	14×14
Layer4	512	3	2	7×7
AvgPool	512	–	–	1×1
FC	15	–	–	15 classes

Số tham số: ~ 21 triệu tham số

Ưu điểm so với CNN baseline:

- Sử dụng **Global Average Pooling** thay vì Flatten \Rightarrow giảm đáng kể số tham số
- **Batch Normalization** ổn định quá trình huấn luyện
- **Skip connections** giúp huấn luyện mạng sâu hiệu quả hơn
- **Kaiming initialization** cho các lớp tích chập

2.2 Cấu hình huấn luyện

Table 4: Cấu hình huấn luyện mô hình ResNet-34

Tham số	Giá trị
Kích thước ảnh	224×224
Batch Size	32
Learning Rate	1×10^{-4}
Weight Decay	1×10^{-6}
Số Epoch	10
Optimizer	AdamW
Loss Function	BCEWithLogitsLoss
Weight Initialization	Kaiming Normal

2.3 Kết quả thực nghiệm

Table 5: Kết quả huấn luyện mô hình ResNet-34 (10 epoch)

Chỉ số	Train	Validation	Test
Loss (epoch cuối)	0.2786	0.3742	–
AUC (epoch cuối)	0.7768	0.5235	~0.53
Best Val AUC	–	0.5293 (epoch 6)	–

Nhận xét:

- **Hiệu suất thấp hơn kỳ vọng:** Val AUC chỉ đạt 0.53, thấp hơn CNN baseline (0.60).
- **Vấn đề có overfitting:** Train AUC (0.78) cao hơn nhiều so với Val AUC (0.52).
- **Nguyên nhân có thể:**
 - Mô hình huấn luyện thiếu dữ liệu huấn luyện
 - Không sử dụng pretrained weights từ ImageNet
 - Số mẫu huấn luyện nhỏ (100 mẫu sample)

So sánh với CNN:

- ResNet-34 có ít tham số hơn nhiều (21M vs 95M)
- Tuy nhiên, vì lượng dữ liệu nhỏ, mô hình đơn giản hơn CNN lại cho kết quả tốt hơn
- Điều này gợi ý rằng cần sử dụng transfer learning cho các mô hình sâu

2.4 Đơn mã minh họa

```

1 class BasicBlock(nn.Module):
2     expansion = 1
3
4     def __init__(self, in_channels, out_channels, stride=1, downsample=None):
5         super(BasicBlock, self).__init__()
6         self.conv1 = nn.Conv2d(in_channels, out_channels,
7                                 kernel_size=3, stride=stride, padding=1, bias=
8                                 False)
9         self.bn1 = nn.BatchNorm2d(out_channels)
10        self.relu = nn.ReLU(inplace=True)
11        self.conv2 = nn.Conv2d(out_channels, out_channels,
12                                kernel_size=3, stride=1, padding=1, bias=False)
13        self.bn2 = nn.BatchNorm2d(out_channels)
14        self.downsample = downsample
15
16    def forward(self, x):
17        identity = x
18
19        out = self.conv1(x)
20        out = self.bn1(out)
21        out = self.relu(out)
22        out = self.conv2(out)
23        out = self.bn2(out)
24
25        if self.downsample is not None:
26            identity = self.downsample(x)
27
28        out += identity # Skip connection
29        out = self.relu(out)
30        return out

```

```

30
31 def create_resnet34(num_classes=15):
32     """Tạo mô hình ResNet-34 với cấu hình [3,4,6,3] blocks"""
33     return ResNet(BasicBlock, [3, 4, 6, 3], num_classes=num_classes)

```

Listing 2: Định nghĩa BasicBlock và hàm _make_layer

3 Mô hình Vision Transformer (ViT-v1 và ViT-v2)

Vision Transformer (ViT) là kiến trúc áp dụng cách self-attention của Transformer (Vaswani et al., 2017) vào bài toán thị giác máy tính. Thay vì sử dụng các lớp tích chập, ViT chia ảnh thành các patch và xử lý chúng như một chuỗi (sequence) các token.

3.1 Kiến trúc ViT-v1

Cu hình mô hình:

Table 6: Cu hình kiến trúc ViT-v1 và ViT-v2

Tham số	Giá trị
Image Size	224×224
Patch Size	32×32
S Patches	$(224/32)^2 = 49$
Embedding Dimension	64
Number of Heads	4
Transformer Layers (Depth)	8
MLP Ratio	2
Dropout	0.1
MLP Head Units	[2048, 1024]

Tổng số tham số: ~ 9.0 triệu tham số

Các thành phần chính:

1. **Patch Embedding:** Sử dụng Conv2d với kernel = patch_size để chia các patch thành embedding vectors.
2. **Positional Embedding:** Learnable positional embedding được cộng vào patch embeddings.
3. **Transformer Encoder:** 8 layers, mỗi layer gồm:
 - Layer Normalization (Pre-LN)
 - Multi-Head Self-Attention (4 heads)
 - Residual Connection
 - Layer Normalization
 - MLP (GELU activation)
 - Residual Connection
4. **Classification Head:** Flatten tất cả patches \rightarrow MLP [2048, 1024, 15]

Lưu ý quan trọng: Mô hình này **không sử dụng CLS token** như trong kiến trúc ViT gốc. Thay vào đó, tất cả patch embeddings sau Transformer được flatten và đưa vào MLP classifier.

3.2 Kiến trúc ViT-v2 và khác biệt so với v1

ViT-v2 có cùng kiến trúc với ViT-v1, nhưng khác biệt về hình huấn luyện:

Table 7: So sánh cấu hình huấn luyện ViT-v1 và ViT-v2

Tham số	ViT-v1	ViT-v2
Optimizer	AdamW	SGD (Nesterov)
Learning Rate	1×10^{-4}	0.01
Weight Decay	1×10^{-6}	1×10^{-5}
LR Scheduler	Không	ReduceLROnPlateau
Early Stopping	Không	Có (patience=3)
Momentum	–	0.9

Các cải tiến trong ViT-v2:

- **Optimizer SGD với Nesterov momentum:** Learning rate cao hơn (0.01) kết hợp với momentum=0.9 giúp hội tụ nhanh hơn.
- **Weight decay nhỏ hơn** (10^{-5} thay vì 10^{-6}): Tăng regularization để giảm overfitting.
- **Learning rate scheduler:** ReduceLROnPlateau giảm LR khi validation loss không cải thiện.
- **Early stopping:** Dừng huấn luyện sớm nếu không cải thiện sau 3 epoch liên tiếp.

3.3 Kết quả thực nghiệm

Table 8: So sánh kết quả ViT-v1 và ViT-v2

Mô hình	Best Val AUC	Best Epoch	Test AUC	Test Acc
ViT-v1	0.6431	4	0.5854	91.33%
ViT-v2	0.5947	9	0.6303	89.67%

Kết quả AUC theo từng bệnh (Per-class AUC):

Table 9: Per-class AUC của ViT-v1 và ViT-v2 trên tập Test

Bệnh	ViT-v1 AUC	ViT-v2 AUC
Cardiomegaly	0.79	1.00
Emphysema	–	0.84
Effusion	0.51	0.73
Nodule	0.68	–
Pneumothorax	0.84	0.69
Atelectasis	0.47	0.32
Pleural_Thickening	0.42	0.68
Mass	0.11	–
Edema	–	0.42
Consolidation	0.61	0.33
Infiltration	0.89	0.52
No Finding	0.53	0.76

Nhận xét quan trọng:

- **ViT-v1 và ViT-v2 có điểm mạnh bổ sung cho nhau:** ViT-v1 tốt hơn Infiltration (0.89), Pneumothorax (0.84), trong khi ViT-v2 tốt hơn Cardiomegaly (1.00), Emphysema (0.84), và No Finding (0.76).
- **Tìm năng ensemble:** Kết hợp hai mô hình có thể cải thiện hiệu suất tổng thể.
- **Các bệnh khó phát hiện:** Mass (AUC=0.11 ViT-v1), Consolidation (0.33 ViT-v2), Atelectasis (0.32 ViT-v2) có AUC rất thấp, cho thấy cần cải thiện đáng kể.

3.4 Đơn mã minh họa

```

1 class PatchEmbedding(nn.Module):
2     def __init__(self, img_size=224, patch_size=32, in_channels=3, embed_dim=64)
3         :
4         super().__init__()
5         self.num_patches = (img_size // patch_size) ** 2
6         # Sử dụng Conv2d để chuyển patch thành embedding
7         self.proj = nn.Conv2d(in_channels, embed_dim,
8                                 kernel_size=patch_size, stride=patch_size)
9
10    def forward(self, x):
11        x = self.proj(x)           # (B, embed_dim, H/P, W/P)
12        x = x.flatten(2)           # (B, embed_dim, num_patches)
13        x = x.transpose(1, 2)      # (B, num_patches, embed_dim)
14        return x
15
16 class TransformerEncoderBlock(nn.Module):
17     def __init__(self, embed_dim, num_heads, mlp_ratio=4, dropout=0.1):
18         super().__init__()
19         self.ln1 = nn.LayerNorm(embed_dim, eps=1e-6)
20         self.attn = nn.MultiheadAttention(embed_dim, num_heads,
21                                             dropout=dropout, batch_first=True)
22         self.ln2 = nn.LayerNorm(embed_dim, eps=1e-6)
23         self.mlp = MLP(embed_dim, int(embed_dim * mlp_ratio), embed_dim, dropout)
24
25    def forward(self, x):
26        # Pre-LN + Self-Attention + Residual
27        x_norm = self.ln1(x)
28        attn_out, _ = self.attn(x_norm, x_norm, x_norm)
29        x = x + attn_out
30        # Pre-LN + MLP + Residual
31        x = x + self.mlp(self.ln2(x))
32        return x

```

Listing 3: Định nghĩa PatchEmbedding và TransformerEncoderBlock

4 Mô hình ViT tiền huấn luyện (Pretrained ViT)

4.1 Kiến trúc mô hình

Mô hình ViT tiền huấn luyện sử dụng từ vựng timm (PyTorch Image Models) đã được huấn luyện trên ImageNet. Đây là phương pháp **transfer learning**, tận dụng kiến thức đã học từ tập dữ liệu lớn để giải quyết bài toán y khoa với ít dữ liệu hơn.

Model được sử dụng: vit_base_patch16_224

Table 10: Cấu hình kiến trúc ViT-Base/16

Tham số	Giá trị
Model Name	vit_base_patch16_224
Pretrained Dataset	ImageNet-21K
Image Size	224×224
Patch Size	16×16
S Patches	$(224/16)^2 = 196$
Embedding Dimension	768
Number of Heads	12
Transformer Layers	12
MLP Ratio	4

Tổng tham số: ~86 triệu tham số

Thay đổi classification head:

- Head gc: Linear $768 \rightarrow 1000$ (ImageNet classes)
- Head mi: Linear $768 \rightarrow 15$ (15 bệnh phi)

So sánh với ViT từ đầu:

Table 11: So sánh ViT Pretrained và ViT from Scratch

Thực tính	ViT Scratch	ViT Pretrained
Patch Size	32	16
S Patches	49	196
Embedding Dim	64	768
Transformer Layers	8	12
S tham số	9M	86M
Pretrained	Không	ImageNet-21K

4.2 Cấu hình huấn luyện

Table 12: Cấu hình huấn luyện ViT Pretrained

Tham số	Giá trị
Batch Size	16
Learning Rate	1×10^{-4}
Optimizer	AdamW
Loss Function	BCEWithLogitsLoss
S Epoch	10
Fine-tuning	Toàn bộ mô hình

Lưu ý về Batch Size: Batch size giảm từ 32 xuống 16 do mô hình lớn hơn đáng kể (86M params vs 9M params), đòi hỏi nhiều GPU memory hơn.

4.3 Kết quả thực nghiệm

Table 13: Kết quả huấn luyện ViT Pretrained

Chỉ số	Train	Validation	Test
Loss (epoch cuối)	0.2425	0.3232	0.3768
Accuracy	90.22%	86.67%	87.00%
AUC (epoch cuối)	0.8820	0.6673	0.6694
Best Val AUC	–	0.6836 (epoch 4)	–

So sánh tổng hợp tất cả các mô hình:

Table 14: So sánh hiệu suất tất cả các mô hình

Mô hình	Params	Best Val AUC	Test AUC	Test Acc	Xếp hạng
CNN Baseline	95M	0.5998	~0.58	~89%	4
ResNet-34	21M	0.5293	~0.53	~91%	5
ViT-v1	9M	0.6431	0.5854	91.33%	3
ViT-v2	9M	0.5947	0.6303	89.67%	2
ViT Pretrained	86M	0.6836	0.6694	87.00%	1

Nhận xét chính:

1. **ViT Pretrained đạt AUC cao nhất (0.6694)**, xác nhận hiệu quả của transfer learning trong y khoa.
2. **Không cách gia pretrained và scratch**: Test AUC tăng từ 0.58–0.63 (scratch) lên 0.67 (pretrained), cải thiện khoảng 7-15%.
3. **Trade-off giữa tham số và hiệu suất**: ViT-v1/v2 chỉ có 9M tham số nhưng đạt AUC gần bằng pretrained (86M params).
4. **Accuracy không phản ánh đúng chất lượng mô hình**: CNN đạt accuracy cao (89%) nhưng AUC thấp (0.58), cho thấy mô hình chỉ dự đoán "No Finding" (chỉ 53.8% dữ liệu).

4.4 Đơn mã minh họa

```

1 import timm
2 import torch.nn as nn
3
4 # Tạo mô hình ViT pretrained từ thư viện timm
5 model = timm.create_model('vit_base_patch16_224', pretrained=True)
6
7 # Thay thế classification head cho bài toán 15 lớp bệnh
8 num_classes = 15
9 model.head = nn.Linear(model.head.in_features, num_classes)
10
11 # Chuyển model lên GPU
12 model = model.to(device)
13
14 # Thông tin mô hình
15 total_params = sum(p.numel() for p in model.parameters())
16 trainable_params = sum(p.numel() for p in model.parameters() if p.requires_grad)
17 print(f"Total parameters: {total_params:,}") # ~86M

```

```
18 print(f"Trainable parameters: {trainable_params:,}")
```

Listing 4: To mô hình ViT Pretrained từ timm

```
1 def compute_auc_safe(targets, outputs, num_classes):
2     """Tính AUC an toàn, xử lý trường hợp chỉ có 1 label value"""
3     # Tìm các class có cả mẫu positive và negative
4     valid_classes = []
5     for i in range(num_classes):
6         unique_labels = np.unique(targets[:, i])
7         if len(unique_labels) > 1: # Cần cả 0 và 1
8             valid_classes.append(i)
9
10    if len(valid_classes) == 0:
11        return 0.0
12
13    # Tính macro AUC chỉ trên các class hợp lệ
14    auc = roc_auc_score(
15        targets[:, valid_classes],
16        outputs[:, valid_classes],
17        average='macro'
18    )
19    return auc
```

Listing 5: Hàm tính AUC vì xử lý trường hợp đặc biệt

Part II

Tổng Kết và Khuyến Nghị

5 Tổng kết kết quả

Qua quá trình thực nghiệm với 5 mô hình khác nhau trên bộ dữ liệu NIH Chest X-ray 14, chúng tôi rút ra các kết luận sau:

1. **Transfer learning là cần thiết:** Mô hình ViT pretrained cho kết quả tốt nhất (AUC = 0.67), cao hơn đáng kể so với các mô hình huấn luyện từ đầu.
2. **Kiến trúc đơn giản có thể hiệu quả với dữ liệu nhỏ:** CNN baseline (95M params) đạt AUC tương đương ViT scratch (9M params) trên tập dữ liệu sample nhỏ.
3. **AUC là metric quan trọng hơn accuracy:** Accuracy cao (89-91%) không phản ánh chính xác khả năng phân loại bệnh do class imbalance nghiêm trọng.
4. **Các bệnh hiếm cần đặc biệt chú ý đặc biệt:** Mass, Hernia, Pneumonia có prevalence < 2% và AUC thấp hơn 0.5.

6 Khuyến nghị cải tiến

6.1 Về kiến trúc mô hình

- Sử dụng Global Average Pooling thay vì Flatten trong CNN
- Áp dụng pretrained ResNet hoặc EfficientNet cho so sánh công bằng hơn
- Thử nghiệm ViT-Small hoặc DeiT để cân bằng giữa hiệu suất và chi phí tính toán

6.2 V huấn luyện

- Sử dụng Focal Loss hoặc Weighted BCE để xử lý class imbalance
- Áp dụng Cosine Annealing LR scheduler
- Tăng số epoch và sử dụng early stopping vì patience lớn hơn
- Huấn luyện trên toàn bộ dataset (112,120 ảnh) thay vì sample

6.3 Ví dụ

- Sử dụng patient-level split để tránh data leakage
- Giảm horizontal flip probability (0.3 thay vì 0.5) do đặc thù lâm sàng
- Áp dụng thêm augmentation: MixUp, CutMix, AutoAugment

6.4 Đánh giá

- Báo cáo per-class AUC cho tất cả 15 bệnh
- Sử dụng bootstrap để tính confidence interval
- Thực hiện cross-validation để đánh giá robustness

Tài liệu tham khảo

References

- [1] Jain, A., Bhardwaj, A., Murali, K., & Surani, I. (2024). *A Comparative Study of CNN, ResNet, and Vision Transformers for Multi-Classification of Chest Diseases*. arXiv preprint arXiv:2406.00237.
- [2] Wang, X., Peng, Y., Lu, L., Lu, Z., Bagheri, M., & Summers, R. M. (2017). *ChestX-ray8: Hospital-scale chest x-ray database and benchmarks*. IEEE CVPR.
- [3] Dosovitskiy, A., et al. (2020). *An image is worth 16x16 words: Transformers for image recognition at scale*. ICLR 2021.
- [4] He, K., Zhang, X., Ren, S., & Sun, J. (2016). *Deep residual learning for image recognition*. IEEE CVPR.
- [5] Vaswani, A., et al. (2017). *Attention is all you need*. NeurIPS 2017.